

# Checkpoint 5

## Classificação de vinhos com modelos de árvores

Data Science & Statistical Computing  
FIAP • Prof. Jones Egydio • 2026

Comparação de Random Forest, XGBoost e LightGBM, com Grid Search, Optuna e aplicação Streamlit.

| RM     | Integrante               |
|--------|--------------------------|
| 564711 | Pedro Rodrigues Almeida  |
| 561732 | Alexandre Martins Lucas  |
| 562298 | Vitor Carvalho Alexandre |
| 570133 | Gabriel Barbosa          |

## Problema e escopo

Identificar a classe de cultivar de uma amostra de vinho a partir de 13 medidas químicas. Trata-se de classificação multiclasse supervisionada; não é uma estimativa de qualidade ou preço. A base Wine contém 178 amostras de três classes de vinhos da mesma região da Itália.

## Resultado principal

LightGBM com Optuna foi escolhido exclusivamente pela validação cruzada: F1 macro de 0,9665, com desvio de 0,0243. No teste reservado, acertou 36 de 36 amostras. A base pequena e histórica limita a validade externa desse resultado.

## Estado da entrega

Notebook preenchido e executado, aplicação testada, artefato do pipeline e registros dos experimentos incluídos. Publicação no GitHub e no Streamlit público pendente; os endereços reais precisam ser registrados antes da submissão.


Fonte: Aeberhard, S. & Forina, M. (1992). Wine [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C5PC7J. Licença CC BY 4.0. Obtenção: `load_wine(as_frame=True)`, distribuído com scikit-learn.

# 1. Dados, preparação e protocolo

Cada linha é uma amostra; 13 medidas numéricas formam X e target forma y. As classes originais 1, 2 e 3 são representadas por 0, 1 e 2. O alvo e o índice da linha não entram nos modelos. As medidas incluem álcool, ácido málico, cinzas, magnésio, compostos fenólicos, cor e prolina.

A separação estratificada 80/20, seed 42, reservou 36 amostras. As 142 de treino sustentam toda exploração e as buscas. Três folds estratificados fixos são compartilhados entre algoritmos. O F1 macro dá o mesmo peso às três classes; acurácia, precisão/recall macro e log loss complementam a avaliação.

No treino: zero ausências, duplicatas exatas, infinitos e medidas não positivas. Mantivemos as 142 linhas e 13 entradas, sem remover extremos sem fundamento. A mediana foi colocada dentro dos pipelines, sem alterar os dados completos desta base. Árvores dispensam padronização.



Os tamanhos das classes diferem; medidas químicas mostram separação parcial e sobreposição. Isso sustenta a combinação de atributos e o uso de F1 macro. A correlação entre medidas fenólicas indica redundância, mas não motivou seleção orientada ao alvo.

## 2. Baselines e tuning comparável


Cada modelo recebeu 8 configurações de Grid Search e 20 trials Optuna/TPE, totalizando 84 configurações de busca e 252 ajustes nos três folds. As nove configurações abaixo foram avaliadas sob o mesmo protocolo. Tempo de busca exclui a reavaliação comparativa e o ajuste final.

| Modelo        | Estratégia | F1 treino | F1 CV  | Desvio | Busca (s) |
|---------------|------------|-----------|--------|--------|-----------|
| Random Forest | Baseline   | 1.0000    | 0.9525 | 0.0508 | -         |
| XGBoost       | Baseline   | 1.0000    | 0.9300 | 0.0487 | -         |
| LightGBM      | Baseline   | 1.0000    | 0.9512 | 0.0257 | -         |
| Random Forest | Grid       | 0.9964    | 0.9525 | 0.0508 | 2.49      |
| XGBoost       | Grid       | 1.0000    | 0.9300 | 0.0487 | 0.67      |
| LightGBM      | Grid       | 1.0000    | 0.9589 | 0.0362 | 0.50      |
| Random Forest | Optuna     | 1.0000    | 0.9525 | 0.0508 | 5.14      |
| XGBoost       | Optuna     | 1.0000    | 0.9525 | 0.0508 | 1.38      |
| LightGBM      | Optuna     | 1.0000    | 0.9665 | 0.0243 | 0.92      |

Os três baselines obtiveram F1 de treino 1,0000. O gap de 0,0700 do XGBoost foi o maior; Random Forest e LightGBM ficaram próximos em CV. O LightGBM mostrou menor dispersão inicial. Treino perfeito, sozinho, não demonstra generalização.


Grid: RF varia árvores, profundidade e mínimo por folha; XGBoost varia árvores, profundidade e taxa; LightGBM varia árvores, folhas e taxa. Optuna também explora max\_features no RF, peso mínimo/subamostragem de colunas no XGBoost e mínimo de amostras por folha no LightGBM. Os espaços exatos e resultados completos estão no notebook e nos CSVs.

RF não melhorou com Optuna, apesar do custo maior. XGBoost ganhou 0,0225 de F1 sobre a grade. LightGBM ganhou 0,0076, com menor desvio entre folds. Os orçamentos diferem e os ganhos são pequenos frente à dispersão; não afirmamos superioridade estatística nem estabilidade entre sementes.




### 3. Escolha, aprendizado e interpretação

Regra prévia: maior F1 médio de CV; até 0,005 de diferença configura empate prático, resolvido por menor desvio e depois tempo. LightGBM/Optuna foi o único elegível. Parâmetros: 100 árvores, learning\_rate 0,1499993, num\_leaves 7 e min\_child\_samples 6; max\_depth 3 permanece do baseline.




A validação vai de 0,9146 a 0,9665, com queda intermediária para 0,8980 nas menores subamostras. O treino permanece 1,0000; o gap final 0,0335 indica variância residual. O crescimento com mais dados sugere benefício potencial de ampliar a base; não elimina sobreajuste.



Importância nativa normalizada: descreve contribuição nos cortes das árvores e pode distribuir peso entre variáveis correlacionadas. Não demonstra causalidade. A matriz de confusão OOF do treino está no notebook; o teste permaneceu isolado até a etapa final.

## 4. Teste final e cinco casos de consistência

Após a escolha, o pipeline foi reajustado somente nas 142 amostras de treino. As previsões do teste foram calculadas uma vez e reutilizadas nas métricas e análises. Não houve revisão da seleção após o teste. F1 macro, acurácia e precisão/recall macro: 1,0000. Log loss: 0,00521.



O F1 de teste ficou 0,0335 acima da CV. Acurácia de 36/36 tem intervalo de Wilson de 95% aproximadamente [0,904; 1,000], sob independência. O teste é pequeno e da mesma origem; não valida novas safras ou laboratórios.

| ID  | Álcool | Flavon. | Prolina | Real | Prev. | Prob.    |
|-----|--------|---------|---------|------|-------|----------|
| 121 | 11.56  | 5.08    | 465     | 1    | 1     | 0.901738 |
| 108 | 12.22  | 2.04    | 312     | 1    | 1     | 0.999999 |
| 66  | 13.11  | 3.18    | 502     | 1    | 1     | 0.923289 |
| 62  | 13.67  | 1.79    | 630     | 1    | 1     | 0.998025 |
| 130 | 12.86  | 1.25    | 630     | 2    | 2     | 0.998289 |

Não houve caso incorreto no teste. A amostra 121 é o acerto de menor confiança (90,17%) e contém flavonoides acima do máximo observado no treino. A amostra 108 exemplifica confiança alta. Isso mostra que previsão correta pode coexistir com entrada fora da faixa histórica; probabilidades não foram calibradas.

Os cinco casos não participaram do treinamento. O CSV de consistência inclui todas as entradas e probabilidades. A interface confirmou classe e probabilidades idênticas às do notebook nos cinco casos, por teste automatizado Streamlit AppTest.

## 5. Reprodução, demonstração e conclusão

O pacote inclui notebook executado, app.py, inference.py, requirements.txt, execute\_notebook.py, pipeline.joblib, metadados, gráficos, resultados brutos e teste da interface. O roteiro distribui uma apresentação de 9min30 entre os quatro integrantes.

### Executar localmente

1. Criar e ativar um ambiente virtual Python 3.12.
2. Executar: `python -m pip install -r requirements.txt`
3. Abrir a interface: `python -m streamlit run app.py`
4. Para refazer os experimentos: `python execute_notebook.py`
5. Conferir paridade: `python tests/test_app.py`

A execução entregue rodou todas as células sequencialmente via IPython no mesmo processo, pois o ambiente não permitiu iniciar o kernel por socket. As saídas preservadas são reais. O executor nbclient incluído permite Run All em ambiente Jupyter normal. A paridade da interface foi validada após o ajuste final.

### Demonstração sugerida

Selecionar o caso 121, classificar e comparar classe 1 com o notebook. Mostrar a probabilidade de aproximadamente 90,17% e o aviso de faixa de treino. Comparar com o caso 108. A interface carrega o pipeline serializado; não treina outro modelo nem recalcula a preparação com dados de teste.

### Publicação pendente

Criar o repositório GitHub, enviar os arquivos e conectar o repositório ao Streamlit Community Cloud com app.py como entrada e Python 3.12. Conferir o caso de paridade na versão publicada. Preencher links.json e registrar as URLs finais no README e notebook. Não há deploy público realizado nesta entrega.

### Conclusão

Neste protocolo, LightGBM/Optuna conciliou o maior F1 de validação com a menor dispersão entre as configurações de melhor score. O teste reservado foi favorável, mas a amostra reduzida e a reutilização de CV na seleção exigem cautela. Próximos passos: mais amostras, avaliação por safra/laboratório, CV repetida ou aninhada e análise de calibração.

### Fontes e evidências

UCI Wine: [archive.ics.uci.edu/dataset/109/wine](https://archive.ics.uci.edu/dataset/109/wine)

scikit-learn: [scikit-learn.org/stable/modules/generated/sklearn.datasets.load\\_wine.html](https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html)

Resultados próprios: results/comparacao.csv, melhores\_parametros.json, aprendizado.csv, consistencia.csv e paridade\_interface.json.